

ViewFormer 기반 다중 시점 3D 점유 인지 성능 향상을 위한 객체 마스크 모듈

Object Mask Module for Enhancing Multi-view 3D Occupancy Perception Performance Based on ViewFormer

전 현 식¹, 김 유 민², 하 종 은^{3,*}

(Hyun-Sik Jeon¹, Yu-Min Kim², and Jong-Eun Ha^{3,*})

^{1,2}Graduate School of Automotive Engineering, Seoul National University of Science and Technology

³Department of Mechanical and Automotive Engineering, Seoul National University of Science and Technology

Abstract: This study examines enhancing object detection by integrating an object-masking module into ViewFormer, a transformer-based model for 3D occupancy prediction from multi-view images. While ViewFormer effectively captures spatiotemporal information, it underperforms on small objects such as pedestrians and bicycles. To address this limitation, we designed a SegFormer-based object masking module that estimates object probabilities from BEV features and concatenates them as an additional feature channel. Experimental evaluations on the nuScenes dataset revealed an unexpected performance decline in overall metrics (mIoU, IoUgeo), particularly for small object detection. Subsequent analysis indicated weak mask activation and instability during initial training as key factors limiting the module's effectiveness. These findings highlight the viability and constraints of object masking, underscoring the need for structural adjustments and improved training strategies to stabilize mask learning in future work.

Keywords: autonomous driving, deep learning, 3D occupancy, viewformer, BEV representation, object masking

I. 서론

딥러닝 기술의 발전은 기존의 수학적 모델링을 대체하며, 자율주행 시스템의 인지, 판단, 제어 전 과정에 핵심적인 역할을 수행하고 있다. 그 중에서도 카메라 기반 인지 기술은 낮은 비용과 센서 구성의 유연성 측면에서 각광받고 있다. 이에 비전 중심(vision-centric)의 자율주행 시스템에서는 주변 환경을 입체적으로 파악하기 위한 3차원 공간 인식 정밀도가 중요한 과제로 부각 받고 있으며, 특히 3차원 점유 영역(3d occupancy) 기반의 표현은 객체와 배경을 통합적으로 인식하고 표현할 수 있다는 점에서 활발히 연구되고 있다.

ViewFormer [1]는 멀티 뷰(multi-view) 이미지로부터 3차원 점유 영역과 flow를 예측하는 트랜스포머(transformer) 기반 모델로, 공간 및 시간 정보의 통합 처리에 강점을 가진 구조다. 구체적으로, Streaming Temporal Attention과 View Attention 모듈을 포함하고 있어 시공간적 정보를 효과적으로 처리할 수 있는 장점을 갖는다. 본 모델은 주요 벤치마크에서 경쟁력 있는 성능을 보였으나, 특정 객체에 대한 탐지 성능은 아쉬운 결과를 보였다. 특히, 보행자와 자전거와 같이 소형의 동적 객체의 인지 성능은 비교적 낮은 수준이며, 이는 도심지 등의 복잡한 환경에서 안전성과 직결된 문제로 볼 수 있다. 이러한 객체들이 주행 환경에서 충분히 감지되지 않을 경우,

자율주행 시스템의 경로 계획이나 제어 판단이 부정확해질 수 있으며, 결국 안정적인 시스템 운용 제한으로 이어진다.

본 논문은 ViewFormer의 전반적인 객체 인지 성능을 개선하고자, BEV (Bird's-eye View) 공간 내 객체 표현을 강화할 수 있는 객체 마스크(object mask) 모듈을 설계하였다. 모듈은 객체가 포함된 영역을 식별한 뒤, 해당 정보를 BEV 특징치(feature)에 채널 형태로 추가하는 방식으로 결합(concatenate)하여 객체 정보를 강조하는 역할을 수행한다. 객체 마스크는 SegFormer [2] 기반으로 구성되며, 모델 학습 중 생성된 BEV 특징치 맵으로부터 객체 존재 확률을 예측하고, 그 결과를 원본 특징치에 반영하는 구조로 설계되었다.

II. 관련 연구

3차원 점유 영역 예측은 자율주행 인지 시스템에서 환경의 정밀한 공간 이해를 가능하게 하는 핵심 기술로 자리잡고 있다. 특히, 멀티 뷰 이미지로부터 3D 공간을 재구성하는 비전 중심 접근은 추가적인 라이다 센서 없이도 주행 환경을 인지할 수 있어 많은 연구가 진행되고 있다. ViewFormer 역시 이러한 비전 기반 점유 예측 모델 중 하나이며, ViewFormer와 유사한 구조를 가진 최근 제안된 Occupancy 예측 모델 연구들은 아래와 같다. 이때 수치들은 비율 값을 뜻한다.

* Corresponding Author

Manuscript received June 24, 2025; revised July 25, 2025; accepted August 20, 2025

전현식: 서울과학기술대학교 자동차공학과 대학원 석사과정(engineer0104@seoultech.ac.kr, ORCID[®] 0009-0006-3150-6866)

김유민: 서울과학기술대학교 자동차공학과 대학원 석사과정(kym3295@seoultech.ac.kr, ORCID[®] 0009-0005-2662-5978)

하종은: 서울과학기술대학교 기계·자동차공학과 교수(jeha@seoultech.ac.kr, ORCID[®] 0000-0002-4144-1000)

※ 이 논문은 2025년도 정부(산업통상자원부)의 재원으로 한국산업기술진흥원의 지원을 받아 수행된 연구임(RS-2024-00406796, 2025년 산업혁신인재성장지원사업). 이 논문은 정부(과학기술정보통신부)의 재원으로 한국연구재단의 지원을 받아 수행된 연구임(No. 2023R1A2C1005870).




그림 1. ViewFormer [1] 구조.

Fig. 1. The structure of ViewFormer [1].

ProtoOcc [3]는 멀티 뷰 이미지로부터 저해상도 쿼리를 사용한 효율적인 3D 점유 예측을 제안하였다. 군집화(clustering)된 2D 이미지 영역에서 파생된 프로토타입을 3D Voxel 공간에 매핑하고, 대조 학습(contrastive learning)을 활용해 쿼리의 표현력을 향상시켰다. 이를 통해 높은 표현력을 유지하면서도 25% 수준의 쿼리 수만으로 TPVFormer를 능가하는 39.01 mIoU를 기록하였다. BiC-Occ [4]는 2D 이미지와 3D Voxel 간의 양방향 변환이 가능한 구조를 제안하여 label 희소성 문제(sparsity problem)를 해결하였다. 다중 해상도의 BEV 표현 정렬과 Circulated Loss를 도입하여 일관성 있는 점유 예측을 달성하였으며, Occ3D-nuScenes에서 44.60 mIoU의 성능을 입증하였다. GaussianFlowOcc [5]는 3D Gaussian 표현과 시간적 흐름을 결합한 약지도(weakly supervised learning) 점유 예측 기법을 제안하였다. 사전 학습된 2D 모델에서 추출된 Pseudo-label과 Temporal flow를 활용하여 3D annotation 없이도 학습이 가능하며, 16.02 mIoU를 기록하였다.

GaussRender [6]는 Gaussian 렌더링을 이용하여 다시점 일관성 손실을 도입한 새로운 Supervised 방식이다. 시점별 예측 Voxel을 2D 이미지 공간으로 투영하여 부정확한 예측을 제어하고, 이를 통해 기존 TPVFormer 대비 30.48 mIoU로 2.65만큼 향상하였다. TGP [7]는 sparse point와 3D Gaussian 표현을 결합한 이중 표현 통합 구조를 제안하였다. 적응형 디코더 구조를 통해 공간 구조를 정밀하게 포착하며, Occ3D-nuScenes에서 34.50 mIoU 성능을 달성하였다. COTR [8]는 Compact Occupancy Transformer 구조를 통해 geometry-aware, semantic-aware한 점유 예측을 수행하였다. Coarse-to-fine 그룹 디코더와 명시적-암시적 뷰 변환 전략을 도입하여 BEVDet4D 대비 5배 이상의 연산량 절감과 함께 5.38% 향상된 41.39 mIoU 성능을 보였다. DHD [9]는 기존 BEVPooling과 VoxelPooling의 문제점을 보완하기 위해 명시적 height prior를 도입하였다. MGHS (Mask-Guided Height Sampling)과 SFA (Synergistic Feature Aggregation) 모듈을 통해 높이 기반 특징치 디커플링 및 강

화된 표현을 구현하였으며, DHD-M은 41.49, DHD-L은 45.53의 mIoU를 기록하였다.

위와 같이 최근의 연구들은 공간 구조에 대한 인식 정확도를 높이기 위해 다양한 구조적 개선과 학습 전략을 도입하고 있으며, 특히 Gaussian 표현, Height prior, 시점 간 일관성 기반 학습 등은 3D 점유 예측의 정확도를 향상시키는 데 기여하고 있다.

III. 접근 방법

1. ViewFormer 모델 구조

본 논문에서 기반으로 삼은 ViewFormer의 구조는 그림 1과 같다. ViewFormer는 멀티 뷰 이미지로부터 3차원 공간의 점유 상태(occupancy) 및 점유 흐름(occupancy flow)을 정밀하게 예측하기 위한 비전 중심 트랜스포머 기반 프레임워크이다. 모델은 크게 공간 상호작용(spatial interaction)과 시간 상호작용(temporal interaction)으로 구성되어 있으며, 각각 view attention과 streaming temporal attention 모듈로 이루어져 있다. 두 모듈은 모두 트랜스포머 인코더 내에 통합되어 있으며, query는 72채널의 Voxel과 126채널의 BEV 셀로 작동한다.

공간 상호작용에서 ViewFormer는 3D 정보 수집을 위해 해상도 한계가 존재하는 기존 BEV query 대신 Voxel query를 사용한다. 모델의 핵심 방법론은 기존 projection-first [10] 방식의 단점을 개선한 View Attention 구조이다. 구체적으로, query와 연관된 학습 가능한 Reference point를 중심으로 주변 3차원 영역을 학습하는 VC (View Coordinate) 시스템을 설계하였다. 좌표계 내에서 학습된 샘플 포인트들은 각 카메라 뷰에 맞춰 이미지로 투영되어 특징치를 추출한다. 이 구조는 기존 Deformable Attention [11] 기반 방식의 하나의 이미지에서 특징치를 추출하는 것이 아닌, 여러 시점의 특징치를 통합하고 추출한다.

시간 상호작용은 Streaming Video 개념을 기반으로 한다. ViewFormer는 4개의 과거 프레임 정보를 저장하는 Streaming




그림 2. 제안하는 객체 마스크 모듈이 적용된 ViewFormer 전체 구조. 카메라 표시는 각각 그림5의 시각화 위치를 뜻함. 📷: (a). 🚗: (b), (c). 🚲: (d).

Fig. 2. Overall architecture of ViewFormer with the proposed Object Mask module. The camera icons indicate the corresponding positions visualized in Fig. 5. 📷: (a). 🚗: (b), (c). 🚲: (d).

memory queue를 사용하여, 각 프레임별 BEV 특징치가 queue에 순서대로 입력된다. 모델은 현재 Voxel query를 Z축 방향으로 압축하여 BEV query로 만든 뒤, memory queue에 저장된 과거 BEV 특징치와 상호 작용한다. 이러한 구조는 Voxel-to-BEV 대비 연산량이 적고, 비어 있는 Voxel의 영향을 줄인다. 이후 BEV query는 다시 Voxel query로 복원되며, nuScenes [12] 데이터셋을 입력으로 사용한 ViewFormer는 X, Y, Z축을 기준으로 $[-40m, 40m] \times [-40m, 40m] \times [-1m, 5.4m]$ 범위를 $100 \times 100 \times 8$ 해상도의 Voxel 그리드로 표현하여 점유 상태 및 흐름을 예측한다. 이때, 예측 결과는 nuScenes 데이터셋을 기반으로 구축된 Occ3D 벤치마크의 $200 \times 200 \times 16$ 해상도 Voxel 라벨과 정렬되도록 보간 후 평가된다.

모델은 주행 장면 전체의 시각 정보를 통합하여 처리하는 데에 우수하나, 이러한 구조를 가지고 있음에도 불구하고 ViewFormer는 주요 객체인 차량 기준 52.85로 테스트 성능 측면에서 낮은 탐지율을 가진다. 또한 상대적으로 작은 크기의 객체인 소형 객체 탐지율은 보행자 기준 28.01를 보였다. 이는 고속도로와 같이 주로 차량이 주행하는 개방된 환경에서는 상대적으로 큰 영향을 미치지 않지만, 보행자와 자전거가 빈번하게 나타나는 도심지 환경에서는 주행 능력이 더욱 감소될 수 있다.

특히, 협소한 도로 등의 정밀한 인지가 요구되는 상황에서는, 소형 객체의 누락이 곧 탐지 실패로 이어지며, 이는 자율주행의 정확한 경로 계획이나 차량 제어에 있어 제한 요소로 작용된다.

결론적으로, ViewFormer의 객체 인지 성능을 향상시키기 위한 구조적 보완이 요구되며, 본 논문에서는 위와 같은 한계를 개선하기 위해 객체 특성 강화 모듈 역할을 수행할 객체 마스크를 추가하는 방안을 제안한다.

2. 초기 접근 시도

초기 접근 방안으로 데이터 증강 기법을 고려하였다. 접근의 타당성을 검증하기 위해, 실험 환경에서 ViewFormer의 주요 4개의 클래스 성능과 데이터셋을 분석한 결과, 주요 동적 객체인 차량(413,318개)과 버스(13,163개)는 각각 52.61과 45.81의 높은 탐지율을 기록한 반면, 소형 객체인 보행자(175,361개)와 자전거(11,917개)는 각각 27.63, 27.88의 낮은 탐지율을 보였다. 특히 보행자는 버스보다 객체 수가 많음에도 불구하고 탐지 성능은 현저히 낮게 나타났다. 이는 객체 탐지율이



그림 3. 객체 마스크 학습을 위한 GT 이미지. 3D 시맨틱 레이블로부터 BEV 기반의 이진 객체 마스크를 생성.

Fig. 3. Ground truth mask for object mask learning. BEV-based binary mask generated from 3D semantic labels.

객체 수보다는 크기와 밀접한 연관성이 있음을 보여준다. 이러한 현상은 자동차 전용도로와 같은 환경에서는 큰 문제로 부각되지 않으나, 소형 객체가 빈번히 등장하는 도심지에서는 주행 안전에 부정적인 결과를 초래할 수 있다.

따라서 도심지 주행 상황에서 탐지율을 높이기 위해 다음과 같은 두 가지 모델 구조 개선 방안을 고안하였다.

첫 번째 방안은 주행 환경에 따른 동적 탐지 객체 조정 방식이다. 이 방식은 주행 환경에 따라 모델이 탐지해야 할 객체의 종류를 능동적으로 선택하여 처리 자원을 효율적으로 활용하도록 한다. 예를 들어, 차량 속도가 높은 고속도로 환경에서는 차량이나 버스 등 대형 객체 위주로 탐지를 수행하고, 속도가 낮은 도심지에서는 보행자와 자전거 같은 소형 객체 탐지를 강화한다. 이때 환경 판단은 차량(ego)의 주행 속도를 기준으로 하며, 추가적으로 HD Map을 활용해 현재 차량의 위치가 고속도로 또는 도심지임을 파악할 수 있다. 하지만, 고속도로의 교통 정체 시에는 속도 기반 환경 판단이 부정확할 수 있으며, 카메라 기반 시스템을 벗어나 HD Map 또는 GNSS 활용이 필요하다는 문제가 있다.

두 번째 방안은 Voxel 밀도와 객체 클래스 점유 비율을 활용하여 주행 환경을 판단하는 방식이다. Occupancy Head에서 출력된 3차원 점유 영역 Grid를 활용해 특정 관심 영역(ROI)의 점유 상태를 분석하고, 객체 클래스 정보를 추가로 이용하여 밀도를 계산한다. 이때 대형 객체(차량, 버스 등)의 복셀 밀도가 높으면 고속도로 환경으로 판단하고, 보행자와 자전거 같은 소형 객체 밀도가 높으면 도심지로 간주한다.

또한, Streaming Temporal Attention 모듈을 통해 연속 프레임 간 객체 밀도의 변화를 관찰하여 환경 전환 상황을 실시간으로 감지할 수 있다. 예를 들어, 특정 구역에서 소형 객체의 밀도가 증가하면 도심지로 환경 전환을 인지하고, 대형 객체의 밀도가 증가하면 고속도로 환경으로 인지하여 모델의 탐지 대상을 변경한다.

그러나 이러한 접근 방식은 도심지임에도 교통량이 적어 객체 밀도가 낮은 경우 정확한 환경 판단이 어려우며, 고속도로에서의 보행자 출현 등 예외 상황 대응과 탐지 모드 전환 시 발생할 수 있는 지연 문제들이 고려된다.

3. Object Mask 모듈

본 논문에서는 위 방안을 고려하여 소형 객체뿐만 아니라 모델의 전반적인 객체 인지 성능을 높이기 위해 객체 마스크 모듈 설계로 접근하였다. 이 모듈은 BEV 공간에서 객체 영역을 식별 및 강조하는 방식으로 작동하며, 구체적으로, streaming temporal attention를 통해 변환된 BEV값을 통해 Mask를 생성하여 표현력을 강화한다. 구성 요소로는 학습용 객체 마스크 GT (Ground Truth) 생성, SegFormer 기반 객체 마스크 예측 모듈이며 모듈로 생성된 BEV 특징치 마스크는 원본 채널과 결합된다. 제안 방법론이 포함된 전체 구조는 그림 2와 같다.

객체 마스크 예측 모듈의 효과적인 학습을 위해 기존 데이터셋을 활용하여 객체 클래스만을 포함하는 2D 객체 마스크 GT를 생성하였다. 본 논문에서는 데이터로 LiDAR 센서 데이터와 이를 기반으로 한 3D 라벨링 도구(nuScenes)의 결과물을 활용하였으며, 이는 각 Voxel의 점유 여부와 시맨틱 클

래스 정보를 포함하는 3차원 배열 형태로 구성된다.

구체적으로, ViewFormer는 점유 격자(occupancy grid)를 사용하여 3D 공간의 점유 상태와 각 위치의 시맨틱 클래스(semantic class)를 동시에 표현한다. 점유 상태 라벨은 각 Voxel의 점유 여부를 나타내며, 시맨틱 클래스는 미리 정의된 클래스 리스트와 매칭된 Voxel의 클래스 라벨이다.

여기서, 객체 마스크 GT를 생성하기 위해, 라벨링된 점유 격자 데이터셋에서 시맨틱 클래스 값이 1이상 10 이하인 요소는 객체 존재 클래스일 경우 객체로 간주하여 1로 설정하고, 배경 클래스는 0으로 처리하여 3차원 이진 객체 마스크 M_{3D} 를 생성한다. 즉,

$$M_{3D}(x, y, z) = \begin{cases} 1 & \text{if } 1 \leq S(x, y, z) \leq 10 \\ 0 & \text{otherwise} \end{cases} \quad (1)$$

여기서 $S(x, y, z)$ 는 각 Voxel 위치의 시맨틱 label을 의미하며, 클래스는 nuScenes 데이터셋 기준으로 총 10개의 객체 클래스(차량, 보행자 등)를 갖는다. 이렇게 구성된 3D 이진 객체 마스크 M_{3D} 는 BEV 형식의 2D 마스크로 변환하기 위해, Z축 방향으로 최대값 투영(max-value projection)을 수행한다. 이는 Z축 방향으로 객체가 하나라도 존재하는 Voxel이라면 누락 없이 BEV 공간에 반영하도록 하기 위함이다. 투영 과정은 다음과 같은 식으로 나타낼 수 있다.

$$M_{BEV}(x, y) = \max_z M_{3D}(x, y, z) \quad (2)$$

이 과정을 통해 생성된 이진 객체 마스크 GT인 M_{BEV} 는 객체 마스크 예측 모듈의 정답 이미지로 사용된다. 결과적으로 생성된 BEV 객체 마스크 GT는 공간적 해상도가 200×200 인 2차원 이진 텐서(tensor)로 표현된다. BEV 객체 마스크 GT는 그림 3과 같다.

이어, 제안 방법론의 핵심인 객체 마스크 예측 모듈은 트랜스포머 기반의 SegFormer를 이용하였다. 예측 모듈은 Streaming Temporal Attention에서 생성된 BEV 특징치 맵을 입력으로 받아 객체 영역을 명확히 구분하는 역할을 수행한다.

표현력 한계를 극복하기 위해 선택된 SegFormer는 계층적 구조의 MixVisionTransformer (mit) 인코더를 통해 별도의 위치 인코딩 없이도 효율적으로 멀티 스케일 특징치를 추출하므로, 다양한 크기와 형태의 객체를 포함하는 BEV 특징치 맵을 효과적으로 분석할 수 있다. 또한, 경량 All-MLP 디코더는 인코더가 추출한 여러 수준의 특징치들을 효율적으로 융합




그림 4. 객체 마스크 예측 모듈로 사용된 SegFormer [2] 구조.

Fig. 4. SegFormer [2] structure used as an object mask prediction module.

하여 로컬 및 글로벌 컨텍스트 정보를 모두 활용한 분할 예측을 수행한다. SegFormer의 구조는 그림 4와 같다.

이러한 SegFormer의 구조적 장점은 BEV 특징치 기반의 객체 마스크 예측 태스크에 가장 적합하다고 판단하였다.

본 논문에서 설계된 객체 마스크 예측 모듈 f_{mask} 는 입력 BEV 특징치 맵 $F_{BEV} \in \mathbb{R}^{D \times H \times W}$ 에 대해, 객체가 존재할 확률을 예측하는 이진 마스크(binary mask)를 출력하며, 전체 예측 과정은 다음과 같은 수식으로 표현할 수 있다.

$$\hat{M} = f_{mask}(F_{BEV}), \hat{M} \in [0,1]^{H \times W} \quad (3)$$

여기서 $\hat{M}$ 은 예측된 객체 마스크로, 각 BEV 특징치에서 객체 존재 확률을 나타낸다. 이 마스크는 이후의 BEV 특징치 강조 및 결합 단계에서 객체 정보를 강조하는 데 사용된다.

이어, SegFormer의 디코더로부터 출력된 특징치 맵은 입력 BEV 특징치의 $\frac{1}{4}$ 크기이므로, 최종 마스크로 사용하기 위해 양선형 보간법(bilinear interpolation)을 통해 원본 BEV 특징치와 동일한 공간 해상도(200×200)로 업샘플링하는 과정을 거친다.

이후, SegFormer로부터 출력된 객체 영역을 보다 명확히 강조하기 위해 예측된 객체 마스크에 임계 값(threshold)을 적용하여 임계 값 미만의 영역(배경)을 제거한다. 이 과정에서 배경에 해당하는 픽셀은 완전히 제거되고, 임계 값 이상의 객체 영역만 남겨 강조된 객체 마스크를 얻는다.

객체 마스크 예측 모듈은 최종적으로 1채널의 객체 예측 마스크 $\hat{M}_{exp}$ 를 출력한다. 예측된 1채널의 객체 마스크는 원본 BEV 특징치에 채널 축으로 결합된다. 이를 수식으로 표현하면 다음과 같다.

$$\hat{B}_t = \text{Concat}(F_{BEV}, \hat{M}_{exp}) \quad (4)$$

여기서, F_{BEV} 는 원본 BEV 특징치, shape은 (B, 126, H, W). $\hat{M}_{exp}$ 은 임계 값 적용 후 예측된 객체 마스크, shape은 (B, 1, H, W). $\hat{B}_t$ 는 객체 마스크가 적용된 Output, shape은 (B, 127, H, W)이다.

다음으로, 모듈이 객체 마스크를 효과적으로 학습하기 위해, 예측된 객체 마스크($\hat{M}$)와 앞서 생성한 객체 마스크 GT(M_{BEV}) 간의 손실(loss)을 도입하여 객체 영역을 명확히 학습하도록 하였다.

구체적으로, 픽셀 단위의 정확도를 평가하는 Binary Cross Entropy Loss와 객체 영역의 전체적인 유사도를 평가하는

Dice Loss를 결합한 형태로 객체 마스크 예측 모듈의 손실 함수를 정의한다.

먼저, Binary Cross Entropy Loss는 예측된 객체 마스크 픽셀 값이 실제 객체 존재 여부를 정확히 예측할 수 있도록 지도하며, 수식은 다음과 같다.

$$\mathcal{L}_{BCE}(\hat{M}, M_{BEV}) = -\frac{1}{N} \sum_{i=1}^N [M_{BEV,i} \log(\hat{M}_i) + (1 - M_{BEV,i}) \log(1 - \hat{M}_i)] \quad (5)$$

여기서 N 은 배치 내 픽셀 수이며, $M_{BEV,i}$ 와 $\hat{M}_i$ 는 각각 GT와 예측된 객체 마스크의 i -번째 픽셀 값을 나타낸다.

Dice Loss는 객체 마스크의 형태 유사성을 고려하여 객체 영역이 정밀하게 일치하도록 유도하며, 수식은 다음과 같다.

$$\mathcal{L}_{Dice}(\hat{M}, M_{BEV}) = 1 - \frac{2 \sum_{i=1}^N (\hat{M}_i \cdot M_{BEV,i}) + \epsilon}{\sum_{i=1}^N \hat{M}_i + \sum_{i=1}^N M_{BEV,i} + \epsilon} \quad (6)$$

여기서 ϵ 은 분모가 0이 되는 것을 방지하기 위한 평활화 계수(smoothing factor)로 $\epsilon = 1.0$ 을 사용하였다.

최종적으로, 본 논문에서 제안된 객체 마스크 손실 함수($\mathcal{L}_{mask}$)는 위의 두 손실 함수를 합산하여, 픽셀 단위의 정확도와 객체 영역의 형태적 유사성 모두를 균형 있게 고려하도록 설계하였다.

$$\mathcal{L}_{mask}(\hat{M}, M_{BEV}) = \lambda [\mathcal{L}_{BCE}(\hat{M}, M_{BEV}) + \mathcal{L}_{Dice}(\hat{M}, M_{BEV})] \quad (7)$$

여기서 손실의 균형을 유지하기 위한 가중치(λ)는 1.0으로 설정하여 두 손실 항목을 동등하게 반영하였다.

위와 같이 정의된 객체 마스크 손실 계산을 통해 객체 마스크 예측 모듈은 객체 영역에 대한 정확한 학습이 가능해지며, 결과적으로 BEV 공간에서 객체 영역 강조 효과가 이뤄지도록 설계하였다.

최종적으로 SegFormer를 예측 모듈로 채택하기까지, 본 연구에서는 몇 가지 초기 모델에 대한 비교 실험을 진행하였다.

예측 모듈로 SegFormer를 선택하기 전, 초기 접근 방식으로 모델의 단순화를 고려하여 픽셀 단위로 객체 영역을 정밀하게 강조할 수 있는 CNN 기반의 간결한 구조를 예측 모듈로 사용하였다.

구체적으로, BEV 특징치는 채널별로 다양한 공간 정보를 내포하고 있다는 것을 고려하여, 모든 채널을 활용하여 객체 영역을 효과적으로 식별할 수 있도록 설계하였다. 이에 예측된 마스크를 채널 추가가 아닌, 채널 수만큼 브로드캐스팅

표 1. 모델 성능 비교.

Table 1. Comparison of model performance.

Method	Training GPU	Test GPU	Training Time	Memory(G)	FPS↑	FLOPs↓	Params↓	IoUgeo↑	mIoU↑
ViewFormer	4090*2	4090*2	5D 22h	13.7	12.2	214.74	99.19 M	71.03	41.37
Try 1 (126⊙126) CNN	4090*2	4090*2	7D 7h	14.1	6.2	242.14	99.28 M	62.48	25.45
Try 2 (126⊕1) CNN	4090*2	4090*2	6D 23h	13.7	12.1	242.14	99.28 M	62.76	25.73
Ours (126⊕1) Seg	4090*2	4090*2	9D 5h	16.2	10.7	249.30	181.21 M	64.89	28.76

표 2. U-Net 예측 모델 성능 비교.

Table 2. Performance comparison of the U-Net prediction model.

Method	Training GPU	Test GPU	Training Time	Memory(G)	FPS↑	FLOPs↓	Params↓	IoUgeo↑	mIoU↑
ViewFormer	4090*2	$\frac{1}{10}$	-	13.7	-	-	99.19 M	65.56	32.23
Try 3 (126⊕1) U-Net	4090*2	$\frac{1}{10}$	-	15.1	-	-	130.30 M	57.94	13.75

표 3. 단일 GPU에서 Seg 모델을 학습했을 때 성능 초기 비교.

Table 3. Early performance comparison when training the Seg model on a single GPU.

Method	Training GPU	Test GPU	Training Time	Memory(G)	FPS↑	FLOPs↓	Params↓	IoUgeo↑	mIoU↑
ViewFormer	3090*1	$\frac{1}{10}$	22D	14.6	-	-	99.19 M	62.88	27.36
Ours - single (126⊕1) Seg	3090*1	$\frac{1}{10}$	32D	14.9	-	-	181.21 M	62.53	28.28

표 4. 모델의 각 클래스별 성능 비교, 각 수치는 클래스 IoU 평균을 나타낸다.

Table 4. Performance comparison of the model by class. Each value represents the average IoU score for the corresponding class.

Method	others	barrier	bicycle	bus	car	const. veh.	motorcycle	pedestrian	traffic cone	trailer	truck	driv. surf.	other flat	sidewalk	terrain	manmade	vegetation
ViewFormer	11.45	49.03	27.88	45.81	52.61	23.56	28.25	27.63	29.95	30.64	38.49	84.60	48.93	57.38	59.86	46.88	40.35
Ours (126⊕1) Seg	7.11	32.48	10.87	26.81	39.58	5.90	10.69	14.78	19.37	15.44	17.61	80.57	40.50	49.83	52.85	33.79	30.78

(broadcasting)하여 확장하여 채널별로 독립적으로 객체 마스크의 영향력을 조절하기 위해 학습 가능한 Scaling 파라미터인 알파(α)를 곱하여 객체 정보가 담긴 원본 BEV 특징치 채널을 선택적으로 강조하도록 설계하였다.

이후 원본 BEV 특징치와 강조된 객체 마스크를 잔차(residual) 방식으로 결합하여 객체 중심의 표현이 강화된 최종 BEV Embedding을 생성한다.

하지만, CNN 기반의 예측 모듈은 Mask에 대한 정확성이 불분명하였다. 이에, 브로드캐스팅 결합 방식 대신 마스크 단일 채널만 추가하는 식으로 변경하였으며, 예측 모듈도 U-Net으로 변경하였다.

결론적으로, 추가적으로 실험한 U-Net 모듈은 CNN 실험에 비해 초기 검증에 낮은 성능이 파악되어 조기 종료하였다. 위 실험에 대한 값은 표 1과 2에 Try1,2,3으로 정리되어 있다.

IV. 실험 결과

1. 실험 환경

학습과 평가는 Ryzen 9 5900X CPU와 NVIDIA RTX 4090 GPU 2장이 탑재된 워크스테이션에서 진행되었다. 사용된 데이터셋은 ViewFormer와 동일한 nuScenes 자율주행 데이터셋이며, 보스턴과 싱가포르에서 수집된 도시 주행 영상이 총 40,157장의 시퀀스 이미지로 구성되어 있다. 이 중 70%인 28,130장은 학습, 15%인 6,019장은 검증, 나머지 6,008장은 평가에 사용되었다.

모델은 총 1,265,850 epoch와 배치(batch) 크기 1로 학습이 진행되었으며, 이는 원본 모델과 같은 조건으로 재현하기 위해 성능 차이를 고려하여 적용된 수치이다.

2. Object Mask 모듈 적용 결과

본 논문에서 제안한 모듈이 적용된 모델 성능을 평가 방식으로 기존 ViewFormer과 같이 분할(segmentation)과 객체 탐지 분야에서 흔히 사용되는 IoU (intersection over union) 평가 지표를 사용하였다. IoU는 모델이 예측한 결과와 실제 정답 간의 공간 중첩도를 계산하여, 각 클래스별 인식의 정확도를 정량적으로 측정하는 방식이며, mIoU (mean intersection over union)는 클래스별 IoU 값을 평균 낸 결과이다. IoU의 계산 수식은 다음과 같다.

$$\text{IoU} = \frac{|A \cap B|}{|A \cup B|} \quad (8)$$

여기서, A는 예측을 뜻하며 B는 정답을 뜻한다. IoUgeo는 지오메트리(geometry) 기반의 IoU를 뜻하며 점유 상태에 대한 점유 예측 정확도를 측정하는 방식이다. 수식은 IoU와 동일하며, 이때 IoUgeo는 시맨틱 클래스는 무시하고 이진 점유(binary occupancy) 상태만 단일 클래스(binary)로 측정한다.

객체 마스크 모듈이 적용된 모델 성능은 표 1과 표 4와 같다. 표 1은 모델의 전체적인 성능을 요약한 것이며, 표 4는 17개의 클래스 단위로 세분화된 평가 결과를 포함한다. 모델 실험 결과, 객체 마스크 모듈 실험 결과, 소형 객체 탐지 성능 강화라는 초기 목표와 달리 전반적인 성능이 하락하였다.




그림 5. 학습 진행도에 따른 객체 마스크 적용 BEV 특징치 변화 시각화. 시각화 위치는 그림2에 표기되어 있음(첫 번째 행: 1%, 두 번째 행: 50%, 세 번째 행: 100%). (a)입력 특징치(Ours Input). (b)제안한 SegFormer 마스크 (Ours). (c)비교 실험용 CNN 마스크 (Ablation). (d)원본 ViewFormer 출력(Baseline).

Fig. 5. Visualization of BEV feature changes caused by the application of object masks across different stages of training. The corresponding visualization positions are marked in Fig. 2(First row: 1%, second row: 50%, third row: 100%). (a) Input features (Ours Input). (b) Proposed SegFormer mask (Ours). (c) CNN-based mask used for ablation (Ablation). (d) Original ViewFormer output (Baseline).

표 1에 정리되어 있듯 객체 마스크 모듈을 적용한 모델의 학습 시간은 9일 5시간(221시간)으로, 원본 모델보다 3일 7시간(79시간)이 더 소요되었다. 초당 프레임 처리 속도(fps)는 12.2에서 10.7으로 원본 모델 대비 소폭 감소했으며, 학습 시 연산에 소모된 메모리는 16.2GB로 기존보다 2.5GB 증가하였다. 부동소수점 연산(FLOPs)량은 249.30로 34.56만큼 증가하였고, 모델 전체 파라미터(parameter)수는 82.02M 증가하였다. 주요 성능 지표 역시 원본대비 mIoU는 41.37에서 28.76으로, IoUgeo는 71.03에서 64.89로 감소를 보였다. 이때 원본 모델은 원본 논문에 명시된 값이 아닌, 본 논문에서 제안한 모듈과 동일한 워크스테이션에서 재학습 및 재평가한 결과이다.

표 4에서는 앞서 초기 접근 시도에서 중점적으로 다뤘던 4가지 동적 객체에 대한 비교 결과도 함께 확인할 수 있다. 모듈을 적용하였을 때 4가지 객체 역시 대형 객체인 버스와 차량은 각각 45.81에서 26.81과 52.61에서 39.58 하락하였고, 소형 객체인 보행자와 자전거는 각각 27.63에서 14.78과 27.88에서 10.87 하락을 보였다. 이러한 결과는 객체 인지 성

능 강화를 목표로 한 설계 의도와는 달리, 전반적으로 성능 저하가 발생했음을 보여준다.

다중 GPU 환경에서 관찰된 성능 저하의 원인을 명확히 분석하고 제안한 모듈의 구조적 유효성을 검증하기 위해, 단일 GPU 환경에서의 비교 실험을 추가적으로 수행하였다. 동일한 코드와 데이터셋을 사용하여 NVIDIA RTX 3090 GPU 1장으로 모델을 학습한 결과, 표 3과 같이 학습 1/10 지점에서 베이스라인 모델 대비 mIoU가 0.92 향상되는 상반된 결과를 확인하였다.

하지만 단일 GPU 환경에서는 전체 학습에 약 32일이 소요될 것으로 예상되어, 현실적인 실험 기간 내 검증을 완료하기 어렵다고 판단하여 조기 종료하였다. 그럼에도 불구하고 이러한 초기 학습 단계의 성능 우위는, 제안한 객체 마스크 모듈의 아키텍처 자체는 유효하게 작동할 수 있으며 다중 GPU의 분산 학습 환경과 상호작용하며 발생하는 문제가 성능 저하의 주요 원인일 수 있음을 나타낸다.

3. 실험 결과 분석

객체 마스크 모듈 적용 이후의 성능 하락 원인은 단순한 파라미터 증가나 연산량 증가로만 설명되기 어렵다. 원인을 분석하기 위해 학습 과정을 그림 5와 같이 학습 진행에 따라 시각화 하였다. 그림 5에서 a는 마스크 모듈이 적용된 입력, b는 제안한 SegFormer 객체 마스크, c는 CNN 시도 시 마스크, d는 마스크 모듈이 적용되지 않은 원본 모델의 출력 시각화 이미지이다. 제안한 방법론은 원본 특징에 마스크를 127번째 채널에 결합하므로, 마스크 적용 후의 모듈 출력 특징치(Ours Output)은 시각화 채널에 따라 다르다. 1~126번째 채널의 경우 입력(a)과 같고, 127번째 채널의 경우 마스크(b)와 동일하다. 시각화는 제안 방법론 기준 126+1개의 BEV 특징 채널 중, 원본 출력과의 비교를 위해 64번째 채널을 기준으로 하였다. 따라서 시각적 중복을 피하기 위해 Ours Output은 생략하였다. 학습이 완료되었을 때를 기준으로 객체 마스크 모듈이 적용되지 않은 원본 모델의 BEV 특징치 맵은 활성화 값이 -1에서 4 사이의 활성화 값을 가지며, 마스크 모듈이 적용된 경우에도 유사한 범위인 -1에서 6의 활성화를 나타냈다.

예측된 마스크의 활성화 분포를 분석한 결과, 객체로 판단한 영역에서도 최대 활성화 값이 0.9 수준으로 이상적 최댓값인 1에 근접했지만, 불 완전한 형태를 보여주며 전반적으로 낮은 신뢰도를 보였다. 이는 마스크 예측 모듈이 객체의 위치와 형태를 정밀하게 학습하지 못했음을 시사한다. 특히, 본 모듈은 원본 BEV 특징치를 입력으로 받아 다시 원본 특징치에 결합되는 순환적 구조를 가지므로, 학습 초기에 아직 불안정한 특징치로부터 생성된 불완전한 마스크가 학습 과정 전체에 부정적인 영향을 미쳤을 가능성이 높다. 결과적으로, 객체 정보가 부족한 마스크는 특징치 강화를 이루지 못하고 오히려 노이즈처럼 작용하여 BEV 공간의 의미론적 일관성을 해치고, 후속 계층의 시공간적 정보 처리 과정에 누적된 간섭을 유발함으로써 전반적인 성능 저하로 이어진 것으로 판단된다.

하지만, 단일 GPU 환경에서 제안한 모듈이 초기 학습부터 베이스라인 모델을 능가하는 성능을 보였다. 이는, 모듈 자체의 설계 유효성을 뒷받침한다. 이와 대조적으로 다중 GPU 환경에서 나타나는 성능 저하는, 단일 학습 환경과 분산 학습 환경 간의 그래디언트 처리 및 동기화 방식의 근본적인 차이에서 비롯된 것으로 추론된다.

결론적으로, 본 논문에서 제시한 모델은 객체 마스크가 불완전하게 학습된 채 적용되었고, 마스크가 노이즈로 작용되면서 원본 특징치의 표현력을 강화하기보다는 왜곡시켜, 전체 모델의 성능 저하로 이어졌을 가능성이 높다고 판단된다. 이어, 단일 GPU에서의 학습을 미루어 보아 분산 학습 환경에 특화된 최적화가 이루어진다면, 제안한 모듈이 본래의 잠재력을 발휘하여 베이스라인 이상의 성능을 달성할 수 있음을 시사한다.

V. 결론

본 논문에서는 ViewFormer의 구조적 한계를 보완하고자 객체 마스크 모듈을 설계하고, 이를 모델에 적용하여 BEV 공간에서 객체 표현 강화 가능성을 확인하였다. ViewFormer

는 멀티뷰 이미지 기반의 3차원 점유 영역 인식에서 경쟁력 있는 성능을 보인 프레임워크지만, 보행자와 자전거와 같은 일부 객체의 탐지율은 여전히 낮은 수치를 보였다. 이에, 객체 인지 성능 강화를 위한 접근으로 BEV 특징치 상의 객체 영역을 강조하는 객체 마스크 모듈을 추가하는 구조를 제안하였다. SegFormer를 기반으로 생성된 객체 마스크를 원본 BEV 특징치에 결합함으로써, 객체 표현을 강화하는 것을 목표로 하였다.

실험 결과, 제안한 모듈은 다중 GPU 학습 환경에서 mIoU 기준 12.61, IoUgeo 기준 6.14가 하락하는 등 전반적인 성능 저하를 보였다.

하지만, 본 방법론은 단일 GPU 환경의 초기 평가에서 베이스라인 모델 대비 mIoU가 0.92 향상되는 긍정적인 결과를 보이며 제안한 접근법의 잠재적 유효성을 입증했다. 이러한 상반된 결과는 성능 저하의 원인이 제안한 구조 자체의 근본적 결함이 아닌, 학습 과정의 불안정성과 환경적 요인에 있음을 시사한다. 구체적으로, 학습 과정 시각화를 통해 확인된 바와 같이, 학습 초기에 불안정한 특징치로부터 생성된 마스크가 의도와 달리 노이즈처럼 작용하여 전체 표현력을 왜곡시킨 것으로 판단된다. 또한, 다중 GPU 환경에서만 성능이 저하된 현상은 분산 학습 환경의 그래디언트 처리 및 동기화 방식 차이에서 비롯된 복잡한 상호작용 문제로 판단된다.

따라서, 향후 연구로는 다중 GPU 환경에서의 학습 안정성 확보를 목표로, 초기 학습 단계에서는 마스크 모듈의 그래디언트 흐름을 제어하여 주 모델의 특징치가 안정적으로 형성되도록 유도하는 점진적 학습 방식과, 마스크의 결합 강도를 학습 진행도에 따라 동적으로 조절하는 어텐션 또는 스케줄링 기법 도입에 대한 연구를 진행할 예정이다.

REFERENCES

- [1] J. Li, X. He, C. Zhou, X. Cheng, Y. Wen, and D. Zhang, "ViewFormer: Exploring spatiotemporal modeling for multi-view 3D Occupancy perception via view-guided transformers," *Proceedings of the European Conference on Computer Vision (ECCV)*, pp. 90–106, 2024.
- [2] E. Xie, W. Wang, Z. Yu, A. Anandkumar, J. M. Alvarez, and P. Luo, "SegFormer: Simple and efficient design for semantic segmentation with transformers," *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.
- [3] G. Oh, S. Kim, H. Ko, H. Chi, J. Kim, D. Lee, D. Ji, S. Choi, S. Jang, and S. Kim, "3D occupancy prediction with low-resolution queries via prototype-aware view transformation," *arXiv preprint arXiv:2503.15185*, 2025.
- [4] Anonymous authors, "BiC-Occ: Bi-directional circulated 3D occupancy prediction for autonomous driving," *Under Review at the International Conference on Learning Representations (ICLR)*, 2025.
- [5] S. Boeder, F. Gigengack, and B. Risse, "GaussianFlowOcc: Sparse and weakly supervised Occupancy estimation using Gaussian splatting and temporal flow," *arXiv preprint arXiv:2502.17288*, 2025.
- [6] L. Chambon, E. Zablocki, A. Boulch, M. Chen, and M. Cord, "GaussRender: Learning 3D Occupancy with Gaussian rendering," *arXiv preprint arXiv:2502.05040*, 2025.

- [7] M. Chen, W. Chen, M. Yang, Y. Zhang, T. Han, X. Li, Y. Li, and H. Zhao, "TGP: Two-modal Occupancy prediction with 3D Gaussian and sparse points for 3D environment awareness," *arXiv preprint arXiv:2503.09941*, 2025.
- [8] Q. Ma, X. Tan, Y. Qu, L. Ma, Z. Zhang, and Y. Xie, "COTR: Compact occupancy TRansformer for vision-based 3D occupancy prediction," *Proc. of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 19936–19945, 2024.
- [9] Y. Wu, Z. Yan, Z. Wang, X. Li, L. Hui, and J. Yang, "Deep height decoupling for precise vision-based 3D Occupancy prediction," *arXiv preprint arXiv:2409.07972*, 2024.
- [10] Z. Li, W. Wang, H. Li, E. Xie, C. Sima, T. Lu, Y. Qiao, and J. Dai, "BEVFormer: Learning bird's-eye-view representation from multi-camera images via spatiotemporal transformers," *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022.
- [11] X. Zhu, W. Su, L. Lu, B. Li, X. Wang, and J. Dai, "Deformable DETR: Deformable transformers for end-to-end object detection," *Proceedings of the International Conference on Learning Representations (ICLR)*, 2021.
- [12] H. Caesar, V. Bankiti, A. H. Lang, S. Vora, V. E. Liong, Q. Xu, A. Krishnan, Y. Pan, G. Baldan, and O. Beijbom, "nuScenes: A multimodal dataset for autonomous driving," *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 11621–11631, 2020.



전 현 식

2024년 신한대학교 미래자동차공학과 졸업(공학사). 2024년~현재 서울과학기술대학교 자동차공학과 대학원 석사과정 관심분야는 딥러닝, 객체인지, 객체 추적.



김 유 민

2023년 서울과학기술대학교 기계시스템디자인공학과 졸업(공학사). 2023년~현재 서울과학기술대학교 자동차공학과 대학원 석사과정. 관심분야는 딥러닝, 딥강화학습, 머신비전.



하 중 은

1992년 서울대 기계공학과(공학사). 1994년 서울대 기계공학과(공학석사). 2000년 KAIST 기계공학과(공학박사). 2000년~2002년 삼성코닝 Advanced Engineering Group 선임 연구원. 2002년~2005년 동명대학교 멀티미디어공학과. 2005년~현재 서울과학기술대학교 기계·자동차공학과 교수. 관심 분야는 딥러닝, 딥강화학습, 로봇 비전, 머신 비전.