

UniAD 모델 경량화 및 성능 비교

UniAD Model Lightweighting and Performance Comparison

전 현 식¹, 박 상 민¹, 하 중 은^{2*}

(Hyun-Sik Jeon¹, Sang-Min Park¹, and Jong-Eun Ha^{2,*})

¹Graduate School of Automotive Engineering, Seoul National University of Science and Technology

²Department of Mechanical and Automotive Engineering, Seoul National University of Science and Technology

Abstract: Recently developed autonomous driving systems based on deep learning typically operate through modular architectures, where separate modules perform distinct individual tasks. While the UniAD framework proposed in the “Planning-oriented Autonomous Driving” paper addresses the limitations of modular approaches through a unified architecture, its complex transformer structure requires substantial computational resources to function. This paper proposes a lightweight version of UniAD to improve the accessibility of multimodal learning. We reduce the computational complexity by lowering the number of transformer layers and queries, the dimensions, and the BEV spatial resolution. Additionally, we optimize memory usage by limiting sampling queries and enabling page-locked memory settings. Experiments with two versions of the lightweight architecture show significant memory reductions: up to 79.92% in Stage 1 and 38.81% in Stage 2 compared with the original UniAD architecture (52.3 GB and 16.67 GB, respectively). Although the lightweight model suffers an overall performance degradation, we discover that progressive resolution expansion during training can enhance its feature extraction capability, particularly in the initial low-resolution learning phase.

Keywords: deep learning, autonomous driving, multimodal, lightweighting

I. 서론

딥러닝의 출현 이후 다양한 산업에 적용되며 혁신적인 변화를 가져왔다[1,2]. 다양한 산업 분야 중 자율주행 산업에 큰 영향을 끼쳤으며 구체적으로 기존 전통적인 기하학 기반 접근 방식에서 딥러닝 기반 방법으로 전환되었다. 이를 통해 정적 및 동적인 환경에서 객체 검출 성능이 향상됨에 따라 자율주행 시스템의 성능 또한 크게 향상되었다[3-7].

현재 자율주행에 적용된 대부분은 시스템은 각기 최적화된 객체 탐지 및 추적(object detection & tracking), HD 맵 구축(HD map generation) 생성 등의 모듈이 독립적으로 결과 도출하여 그 정보를 결합하는 방식으로 작동하고 있다. 이러한 분리된 접근은 모듈 간 정보 공유의 비효율성과 일관성 부족, 오류 축적 등으로 인해 자율주행 성능에 부정적인 영향을 미칠 수 있으며, 통합되지 않은 시스템은 빠르고 정확한 상황 인식 및 판단이 필요한 순간에 목적을 달성하기 어렵다.

위 문제점을 해결하기 위해 UniAD (Unified Autonomous Driving) [3]에서는 자율주행 시스템에서 분리된 모듈들을 하나로 통합하여 상황 인지부터 최종 제어까지 수행하는 UniAD (Unified Autonomous Driving) 풀 스택 프레임워크를 제안하였다. UniAD는 Transformer의 쿼리 인터페이스로 정보가 전달되어 계획하는 방식을 통해 인식, 예측, 계획의 모듈화 작업이 진행된다.

구체적으로 multi-camera view image 데이터를 이미지 백본의 Resnet이 특징을 추출하고, BEVFormer (Bird's Eye View Transformer)를 통해 BEV 표현으로 변환하여 토큰형태로 처리한다. 이어 TrackFormer와 MapFormer가 토큰을 받아 각각 객체를 검출 및 추적(object detection & tracking)하고, 파노픽 세그멘테이션(Panoptic Segmentation)을 수행하여 멀티스케일 피쳐(multi-scale feature)를 출력 및 정제(refine)한다. MotionFormer는 TrackFormer와 MapFormer로부터 각각의 키와 벨류값을 받아 객체 별 상호작용과 경로를 예측하고, OccFormer는 객체 간의 정확한 위치 점유 예측(occupancy prediction)을 수행한다. 마지막으로 Planner가 MotionFormer에서 도출된 객체들의 예상 경로와 OccFormer에서의 객체 점유 정보 및 토큰의 2D 정보를 받아 최적화된 경로를 계획한다. 하지만 UniAD는 깊게 쌓인 Transformer 계층과 고차원 특징 맵(feature map)을 처리하는 과정에서 많은 연산량을 필요로 한다.

본 논문에서는 계산량이 많은 대규모 자율주행 멀티모달의 학습을 위해 구조를 경량화하여 연산량을 줄이는 방법에 대해 다루도록 한다. 이를 통해 고성능 하드웨어에 의존하지 않고 더 많은 센서 데이터 처리가 가능한 방법에 대해 모색하도록 한다. 최종적으로 기존의 기존의 제약을 완화하여 멀티모달 정보를 이용한 자율 주행의 성능을 향상하도록 한다.

* Corresponding Author

Manuscript received October 31, 2024; revised December 21, 2024; accepted February 15, 2025

전현식: 서울과학기술대학교 자동차공학과 대학원 석사과정(engineer0104@seoultech.ac.kr, ORCID[®] 0009-0006-3150-6866)

박상민: 서울과학기술대학교 자동차공학과 대학원 석사과정(smpark5249@seoultech.ac.kr, ORCID[®] 0009-0001-4938-3706)

하중은: 서울과학기술대학교 기계·자동차공학과 교수(jeha@seoultech.ac.kr, ORCID[®] 0000-0002-4144-1000)

* 이 논문은 2024년도 정부(산업통상자원부)의 재원으로 한국산업기술진흥원의 지원을 받아 수행된 연구임(RS-2024-00406796, 2024년 산업혁신 인재성장지원사업). 이 논문은 정부(과학기술정보통신부)의 재원으로 한국연구재단의 지원을 받아 수행된 연구임(No. 2023R1A2C1005870).

II. 관련 연구

UAD [4]는 3D 어노테이션 데이터 라벨링이 없이 end-to-end 자율주행을 구현하기 위한 비지도 학습(unsupervised learning) 방식을 제안하고 있다. 레이블이 없는 데이터에서도 학습 가능한 각도별 인식 사전 학습(angular perception pretext)와 방향 인식 경로계획(direction-aware planning)을 도입하여 경로 계획을 학습한다. 각도별 인식 사전학습은 BEV 공간을 섹터로 분할하여 객체 존재의 여부를 예측한 뒤 2D ROI를 BEV 공간으로 투영하여 레이블을 생성한다. GRU를 기반으로 하는 미래 예측 디코더(dreaming decoder)는 시간축의 향상(temporal enhancement)을 통해 미래 상태를 예측한다. 방향 인식 경로계획(direction-aware planning)은 BEV 피치를 회전하여 다양한 각도를 만들어 데이터를 증강한다. UAD는 UniAD 대비 L2 오차가 5.83% 감소하였고, 충돌율(collision rate)이 38.7% 감소하는 성능을 보였다. 학습 리소스(training resources)는 UniAD 대비 55.7% 감소하였다.

SSR (Sparse Scene Representation) [5]은 기존 E2EAD의 복잡한 인식 작업을 제거하고 16개의 navigation-guided 토큰만으로 학습 장면을 표현하였다. 장면 토큰 학습기(STL, Scenes TokenLearner)를 사용해 BEV 특징을 16개의 압축 토큰으로 변환하고 주행 명령(navigation command)을 활용해 중요 영역에 집중한다. BEV 월드모델은 움직임 인식 정규화를 이용하여 현재 장면 토큰에 움직임을 반영하며, 자기지도 학습(self-supervised learning)을 통해 미래 장면 예측을 진행한다. 토큰 결합기로 예측된 정보를 BEV 토큰으로 복원한다. SSR은 UniAD 대비 L2 오차가 27.2% 감소하였고, 충돌율이 51.6% 감소하는 성능을 보였다. 학습 시간은 UniAD 대비 약 92.3%로 감소하였다.

UAD [4]는 모듈화된 구조를 제거하고 BEV의 각도를 활용해 비지도 학습으로 경로계획을 생성하였고, SSR [5]은 인식 모듈을 제거하고 토큰을 기반으로 미래를 예측하고 경로를 계획하였다. 두 모델 모두 UniAD의 복잡한 모듈 구조를 단순화하는 방식으로 접근하였다.

ShuffYOLOX [14]는 CSPDark53 네트워크를 ShuffDet으로 대체하여 모델 복잡도를 34.57% 감소시키고, FPS를 65% 증가시키는 데 성공하였다. 이러한 경량화 접근법은 자율주행 시스템에서 실시간성과 연산 효율성을 동시에 만족시킨 사례로 평가받는다. TwinLiteNet [15]은 BDD100K 데이터셋에서 0.4M 파라미터로 91.3% mIoU를 기록하며, 경량화와 정확도를 균형 있게 달성한 모델로 주목받고 있다. Mobip [16]은 MobileNetV2를 백본으로 사용하여 객체 탐지, 주행 가능 영역 분할, 차선 검출을

통합적으로 수행하였다. 해당 모델은 NVIDIA Tesla V100에서 58 FPS의 속도를 보여, 자율주행 환경에서 실시간성을 입증하였다. EM-VLM4AD [17]는 자율주행을 위한 멀티프레임 비전-언어 모델로, DriveLM 데이터셋에서 기존 대비 메모리와 연산량을 10배 이상 감소시키면서도 더 높은 성능을 달성하였다. 이 모델은 비전-언어 융합을 통해 자율주행 시스템에서 복잡한 데이터를 효율적으로 처리할 수 있는 경량화 전략을 제시하였다.

CarSNN [18]은 이벤트 기반 카메라와 스파이킹 신경망을 결합하여 객체 분류 작업을 수행하였다. 해당 모델은 Loihi 뉴로모픽 칩에서 83%의 정확도, 0.72ms의 지연시간, 310mW의 전력 소비를 달성하며 자율주행 시스템의 에너지 효율성과 정확성을 증명하였다. MIT 연구진이 개발한 Neural Circuit Policy [19]는 실지렁이(C. elegans)의 신경망 구조를 모방하여 단 19개의 뉴런으로 자율주행 차량을 제어하였다. 이 모델은 단순한 구조에도 불구하고 복잡한 환경에서 높은 의사결정 성능을 보이며 경량화 연구에 새로운 가능성을 제시하였다.

III. 접근 방법

1. UniAD 모델 구조

그림 1은 UniAD의 전체 구조를 보여주고 있다. 백본, 인지, 예측, 계획 부분 등의 네 개의 블록으로 구성되어 있다. UniAD 모델의 학습과정은 두 단계로 나뉘어 진행된다. 단계 1에서는 안정화를 위해 TrackFormer와 MapFormer로 구성된 인지 부분을 학습한다. 구체적으로 멀티 뷰 이미지를 BEVformer를 통해 BEV특징으로 변환하고, 이를 기반으로 주변 차량의 위치와 움직임 패턴 및 도로 구조, 차선 등의 정적 요소를 학습한다. 단계 2에서는 단계 1에서와 동일하게 멀티 뷰 이미지 데이터를 입력 받고 단계 1에서 학습된 동적 객체 정보와 정적 환경 정보를 고정하고 전체 프레임워크를 end-to-end로 학습한다. 단계 1과 단계 2의 손실함수 수식은 다음과 같다.

$$L_1 = L_{track} + L_{map}. \quad (1)$$

$$L_2 = L_{track} + L_{map} + L_{motion} + L_{occ} + L_{plan}. \quad (2)$$

모델을 경량화하기 위해 사전 학습된 인자값을 사용하여 NVIDIA A100 한 대의 환경에서 학습한 결과 1단계 학습 과정에서 과도한 양의 GPU 메모리가 소모되는 것이 확인되어, 모델의 중요 모듈 등에서 베이스 구조로 사용되는 Transformer [8] 구조와 BEVFormer 및 1단계 부분의 모델 구조를 중점적으로 변경하였다.




그림 1. UniAD (Unified Autonomous Driving) [3] 구조.

Fig. 1. The structure of UniAD (Unified Autonomous Driving) [3].




그림 2. Transformer 구조[8].

Fig. 2. The structure of Transformer [8].

모델이 복잡해지고, 많은 연산 량이 발생하는데 주요 원인으로 파악되는 그림 2의 Transformer 알고리즘은 인코더-디코더 구조를 가지며, 각각 여러 층의 멀티헤드 어텐션(multi-head attention)과 위치별 피드포워드 네트워크(position-wise feed-forward network)로 구성된다. Positional encoding 처리가 된 데이터를 선형변환을 통해 쿼리(query), 키(key), 값(value) 형태로 받아 쿼리와 키를 내적하여 어텐션 스코어를 도출하고 이를 값에 적용한다. 이 과정을 여러 개의 헤드에서 병렬적으로 수행한 뒤 잔차 연결(residual connection)과 계층 정규화(layer normalization)을 통해 안정화한다. 인코더는 각각의 쿼리, 키, 값이 하나의 데이터에서 재 구성되어 연산되는 멀티헤드 셀프 어텐션 기법을 사용하지만 디코더에서는 멀티헤드 어텐션

레이어가 셀프-어텐션 과정을 거치고 인코더의 출력을 키와 값으로 받아 계산하는 크로스 어텐션(cross-attention)과정을 거친다. 각 모듈은 토큰과 쿼리, 키, 값을 효과적으로 정보를 공유하고 처리한다.

그림 3은 UniAD 모델의 백본으로 사용되는 BEVformer [9]의 구조를 보여주고 있다. BEVFormer는 트랜스포머(transformer) 구조를 사용하여 자율주행 환경에서 다중 카메라 2D 이미지를 BEV(Bird's Eye View)로 변환하여 3D 공간에서 객체의 위치와 상태를 추론한다. 쿼리는 BEV시점으로 투영된 정보를 찾기 위해 2D 이미지에서 좌표를 추출하고 좌표 정보를 가진다. 키와 값은 ResNet-101 모델의 CNN구조를 거친 특징치 맵(feature map)에서 추출되며 쿼리와 키값을 비교하여 어텐션 점수를 계산한다. 벨류는 실제 정보인 GT (Ground truth)값을 가지고 계산된 어텐션 점수를 바탕으로 키에 대응하는 값을 제공한다. 위 과정을 거쳐 BEV를 생성한다.

2. UniAD 모델 경량화

UniAD 모델의 성능을 최대한 유지하면서 효과적으로 연산량을 줄이기 위해 다음과 같이 구조를 조정하였다. 표 1은 UniAD와 경량화된 버전의 구조를 보여주고 있다.

트랜스포머 구조에서 모델 전체에 적용되는 임베딩된 특징치의 크기와 쿼리 벡터의 차원을 기존 256차원에서 128차원으로 감소하였다. 트랜스포머의 계층(layer) 수를 6에서 4로 깊이를 감소하였으며, 헤드(head) 수를 8에서 4로 줄여 복잡도를 줄여 최종적으로 메모리 용량을 감소하였다. FFN (Feed Forward Network)는 입력 데이터를 비선형 변환하여 복잡한 특징들 간의 관계를 학습한다. 채널 수가 많아질수록 계산 비용이 증가된다. 채널 수를 2048에서 1024로 감소하여 표현 유연성을 적절히 유지하면서 연산량을 줄이도록 하였다.

BEVFormer의 백본으로 사용된 CNN 구조의 Resnet-101를 Resnet-50으로 교체하여 인자수를 감소하였다. BEV의 공간 해상도를 200x200에서 50x50으로 낮추어 각 프레임에서 처리할 데이터양을 감소하였다. 또한 3D공간을 2D로 전환시 투영되는 그리드 크기도 512x512에서 256x256로 함께 감소해 주었다. 시공간 정보를 결합하여 추론 시 시퀀스로 동시에 처리되어야 할 과거 프레임 수 정보를 크기를 5에서 3으로 줄였다.




그림 3. BEVformer [9] 구조.

Fig. 3. The structure of BEVformer [9].

표 1 경량 버전별 구조 비교(표의 두 값은 각각 1단계와 2단계의 구조를 나타냄).

Table 1. Comparison of structures by lightweight version (the two values in the table represent the structures in stages 1 and 2, respectively).

Method	GPU*N (NVIDIA)	Encoder	embed dimensions	layers	heads	FFN channels	BEV resolution	Queue length (stage1)	BEV queries	Seg queries	Learning Rate	Grid Size	Query dimensions (stage2)	Pin memory	Memory threshold
UniAD[3]	A100*16	R101	256	6	8	2048	200x200	5	900	300	2e-4	512	256	False	3
DV-1	3090*3	R101	128	4	8	1024	200x200	3	900	300	1e-6 1e-4	512 256	128	False	3
DV-2	A100*1	R50	128	4	4	1024	50x50 200x200	3	900	300	2e-4	512	128	True	1

2D 공간으로 투영하여 각 위치의 정보를 추출하는 데 사용되는 쿼리 수를 900에서 500으로 감소하였다. 1단계에 속해 있는 MapFormer에서 각 픽셀이나 객체를 분할하거나 라벨링할 때 사용하는 세그멘테이션 쿼리(segmentation query) 수를 300에서 150으로 줄였다. 이와 같이 경량화된 모델의 안정적으로 학습을 위해 학습율(learning rate)을 기존 2e-4에서 1e-4, 1e-6으로 변경하였다.

표 1에서 경량화 모델은 DV (Downscale Version)로 명명하였으며, 원본 모델의 학습 연산에 따라 소모되는 메모리를 기준으로 1단계는 $\frac{1}{5}$, 2단계는 $\frac{1}{2}$ 로 줄이는 것을 목표로 설계하였다.

DV-P (Downscale Version - Prototype): 먼저 경량화 규모를 확인하기 위해 1단계만 학습을 진행하였다. 학습 하드웨어는 i9 10900X CPU와 NVIDIA 3090 GPU 3장에서 학습이 진행되었다. 소모되는 자원을 줄이기 위해 resnet-50을 이용하고 embed dimensions는 128, transformer layer 및 head를 각각 4와 8로 줄여주었으며, FFN의 채널 수는 1024, BEV 해상도는 50x50, queue length는 3, BEV queries는 500, seg queries는 150으로 축소하였다.

그리드 크기와 핀 메모리(pin memory)와 메모리 역치값(memory threshold)값은 원본 모델과 동일하게 유지하였다. 동일한 장비에서 학습된 1단계만 학습된 원본 체크포인트(checkpoint)를 이용한 결과와 비교하였을 때, 1단계의 메모리 소모는 표 2에서와 같이 52.3GB에서 10GB로 성공적으로 감소하였다. 추적(tracking)에 비해 상대적으로 단순한 태스크인 매핑(mapping)은 정적 특징을 추출하기 때문에 크게 영향을 받지 않는 모습을 보였다. 반면 시간에 따른 동적 변화 추적 필요한 추적의 경우, 파라미터 감소로 인해 AMOTA 지표가 93.5%가 하락하는 성능 저하가 결과가 도출되었다. 이는 시계열 정보 처리와 복잡한 동적 패턴 학습이 요구되는 추적 임무의 특성상, 모델 경량화가 성능에 치명적인 영향을 미칠 수 있음을 보여준다. 표 2는 원본 체크포인트를 이용한 테스트한 결과와 DV-P의 성능을 비교한 표이다.

DV-1: DV-P를 이용한 초기 결과를 반영하여 모델의 경량화를 진행하였다. DV-1에서는 Resnet 모델과 BEV 해상도를 원본 모델 크기로 복구하여 데이터의 패턴 학습 능력 및 핵심 정보 추출을 올리고 BEV queries 및 seg queries 복구하여 많은 수의 쿼리를 통해 얻는 장면 학습의 세부 표현 질을 올렸다. 또한, 성능을 올리고자 인자에 대해 세밀하게 반응하고, 최적화

값에 안정적 수렴을 목표로 학습률을 1e-6으로 낮추었다. 2단계 학습에서는 그리드 크기를 128로 줄이고 정확한 학습을 유도하기 위해 학습률을 1e-4로 낮추었다. 2단계 학습에서는 10.5GB의 메모리가 소모되었지만, 1단계에서 학습 메모리 17.9GB가 소모되어 첫 번째 경량화 모델에 비해 2배 가까이 늘어났음을 확인할 수 있었다.

DV-2: 두 번째 모델에서는 학습 환경을 AMD EPYC 7742 CPU와 A100 GPU 1장으로 전환하였다. 대표적인 차이점으로는 CPU가 10코어에서 64코어로 증가하였으며, 캐시용량이 19.25MB에서 256MB로 증가하였다. 또한, 대역폭이 47.3 GB/s에서 252.0 GB/s로 늘어났다. GPU는 텐서(Tensor) 코어가 328개에서 432개로 증가하였고, FP16 (half precision) 또한 35.58 TFLOPS에서 77.97 TFLOPS로 증가하여 약 2.2배정도 증가하였다. 결론적으로 두 번째 학습 환경에서는 기존 경량화 모델 학습 환경보다 대규모 데이터셋을 빠르게 접근하고 병렬적으로 처리하는데 매우 유리하다. 이러한 점을 이용하여 Resnet 모델을 다시 R50으로 낮추었으며, 1단계에서 BEV 해상도는 50X50으로 낮추었다가, 2단계 학습에서 경로 제어 향상을 위해 200x200으로 복원하였다. BEV queries와 seg queries는 추출 능력 저하가 크다고 판단되어 유지하였으며, 학습률 역시 2e-4로 복원 및 그리드 크기도 512로 복원하였다. 또한, 헝가리안(Hungarian) 매칭 과정에서 참값과 일치하는 최대 쿼리 수를 1로 제한하여 대규모 데이터셋 학습에서 발생할 수 있는 연산 병목 현상과 모델이 과적합(overfitting)되는 현상을 방지하였다. 마지막으로, 메모리 효율성을 극대화하기 위해 page-locked memory를 활성화하였다. 메모리 소모량은 1단계에서 10.5GB, 2단계에서 10.2GB가 사용되었다.

표 2. UniAD-base의 1단계 테스트 결과와 경량화 모델 결과 비교.

Table 2. Comparison of UniAD-base phase 1 test results with lightweight model results.

Method	Memory (GB)	Tracking			Mapping	
		AMOTA ↑	AMOTP ↓	IDS ↓	IoU-lane ↑	IoU-road ↑
UniAD (Base)	52.3	0.355	1.34	785	0.301	0.671
DV-P (stage1)	10.0	0.025	1.848	1483	0.306	0.671

IV. 실험 결과

1. 실험 환경

훈련은 매개변수 값과 학습 환경을 바꿔가며 총 2가지 버전으로 실험을 진행하였다. 학습 장비로는 i9 10900X CPU와 NVIDIA 3090 GPU 3장 및 AMD EPYC 7742 CPU와 A100 GPU 1장이 사용되었다. 경량화 모델 모두 각각 훈련 28,130장 (70%), 검증 6,019장 (15%), 테스트 6,008장(15%)으로 이루어진 nuScenes 데이터셋[10]을 사용하였으며, 1단계에서는 6 epoch, 2단계에서는 20 epoch, 두 단계 모두 배치(batch) 크기는 1로 진행하였다.

2. 평가 지표

평가의 경우 각 모듈 별로 나누어 총 15개의 지표를 기준으로 성능을 평가하였다. 평가 지표는 아래와 같이 정의된다.

추적 관련 성능은 nuScenes 데이터셋의 표준 평가 방식 [10]에 따라 AMOTA (Average Multi-Object Tracking Accuracy), AMOTP (Average Multi-Object Tracking Precision), IDS (Identity Switches)로 평가한다. 이에 대한 계산은 다음과 같다.

$$AMOTA = \frac{1}{n-1} \sum_{r \in \{\frac{1}{n-1}, \frac{2}{n-1}, \dots, 1\}} MOTA_r \quad (3)$$

여기서 $MOTA_r$ 은 다음과 같이 정의된다.

$$MOTA_r = \max\left(0, 1 - \frac{FP_r + FN_r + IDS_r - (1-r)GT}{rGT}\right) \quad (4)$$

$$AMOTP = \frac{1}{n-1} \sum_{r \in \{\frac{1}{n-1}, \frac{2}{n-1}, \dots, 1\}} \frac{\sum_{i,t} d_{i,t}}{TP_r} \quad (5)$$

수식에 사용된 변수들은 다음과 같다. TP (True Positive)는 정확히 탐지된 객체 수, FP (False Positive)는 오 탐지된 객체 수, FN (False Negative)은 미 탐지된 객체 수를 의미한다. AMOTA는 recall 임계값 범위에서의 MOTA 평균으로 추적 성능을 평가한다. 이어, AMOTP는 탐지된 객체의 위치 오차를, IDS는 동일 객체 ID 변경 빈도 수를 계산한다.

매핑은 주행 시나리오에서 차선(lanes)과 주행 가능 지역(drivable area)을 평가한다. 구체적으로, 각 클래스별 출력과 GT map 사이의 IoU (Intersection over Union)를 계산하여 정확도를 측정한다.

$$IoU = \frac{|A \cap B|}{|A \cup B|} \quad (6)$$

Motion forecasting은 minADE (minimum Average Displacement Error), minFDE (minimum Final Displacement Error), MR (Miss Rate), EPA (End-to-end Prediction Accuracy) 네 가지 지표를 사용하여 평가한다. Argoverse [11]에 따라, minADE 및 minFDE는 예측된 궤적들 중 GT와 가장 가까운 궤적의 평균 변위 오차 및 최종 시점에서의 최소 변위 오차를 의미한다. MR은 예측 실패율을 평가하기 위해 사용하며, ViP3D [13]에 따라, EPA (End-to-end Prediction Accuracy)는 종합적인 성능을 평가한다. MR과 EPA 지표는 각각 다음과 같이 계산된다.

$$MR = \frac{FN}{TP + FN} = 1 - \text{recall} \quad (7)$$

$$EPA(\hat{S}_c, S_c) = \frac{|\hat{S}_{match, hit}| - \alpha N_{FP}}{N_{GT}} \quad (8)$$

$|\hat{S}_{match, hit}|$ 는 현 시점에서 올바르게 매칭되고 미래 궤적도 정확하게 예측한 객체의 총 개수, NFP는 잘못 예측된 객체

수, NGT는 ground truth 객체 수를 나타내며, α 는 0.5로 설정된 페널티 계수이다. 구체적으로, EPA는 객체 탐지 정확도를 위해 현재 시점의 객체 위치가 GT와 2.0m 이내인지 확인하고, ground truth 객체 수(NGT) 대비 정확히 탐지된 객체 비율 평가한다. 궤적 예측 정확도를 위해 매칭된 객체의 미래 궤적이 GT와 10.0m (5 τ EPA) 이내인지 확인한다. 마지막으로 과다 예측 페널티를 위해 false positive 개수(NFP)에 0.5(α)를 곱해 페널티 부여한다. 따라서 EPA는 세 가지 측면을 하나의 수식으로 통합하여 평가하는 지표이다.

Occupancy 예측은 IoU를 통한 전체 장면 수준과 VPQ (Video Panoptic Quality)로 Video Panoptic Segmentation [12]에서 제안된 바와 같이, 시간 경과에 따른 인스턴스 존재 여부를 고려하여, 객체 추적의 정확도를 평가 및 객체 분할(segmentation)의 품질을 평가한다.




그림 4. 1단계 BEV 특징치 맵 시각화. (a) UniAD. (b) DV-1. (c) DV-2.

Fig. 4. Visualization of BEV feature maps in stage 1. a) UniAD (b) DV-1. (c) DV-2.

표 3. 경량화 버전 별 실험 결과 비교(Memory 항목에서 2개로 나뉘어진 값은 각각 단계 1과 단계 2를 의미).

Table 3. Comparison of experimental results by lightweight version (the two values in the Memory section represent stages 1 and 2, respectively).

Method	Memory (GB)	Tracking			Mapping		Motion Forecasting				Occupancy Prediction				Planning	
		AMOTA ↑ [%]	AMOTP ↓ [m]	IDS ↓ [count]	IoU-lane ↑ [%]	IoU-road ↑ [%]	minADE ↓ [m]	minFDE ↓ [m]	MR ↓ [%]	EPA ↑ [%]	IoU-n. ↑ [%]	IoU-f. ↑ [%]	VPQ-n. ↑ [%]	VPQ-f. ↑ [%]	avg.L2 ↓ [m]	avg.Col. ↓ [%]
UniAD (Base)	52.3 16.67	0.359	1.32	906	0.313	0.691	0.708	1.025	0.151	0.456	63.4	40.2	54.7	33.5	1.03	0.31
UniAD (Small)	과일 미공개 테스트 불가	0.241	1.488	958	0.315	0.689	0.788	1.126	0.156	0.381	59.4	35.6	49.2	28.9	1.04	0.32
DV-1	17.9 10.4	0.000	1.946	1493	0.253	0.615	<u>0.995</u>	<u>1.274</u>	0.130	-0.077	25.7	9.8	15.4	5.7	1.25	0.88
DV-2	10.5 10.2	<u>0.016</u>	<u>1.816</u>	753	<u>0.304</u>	<u>0.684</u>	1.157	1.658	0.208	<u>0.108</u>	<u>43.0</u>	<u>22.0</u>	<u>29.6</u>	<u>15.0</u>	0.97	<u>0.75</u>




그림 5. 모델 별 테스트 결과: 도심지 주행 시나리오. (a) UniAD. (b) DV-1. (c) DV-2.

Fig. 5. Test results by model: Urban driving scenario. (a) UniAD. (b) DV-1. (c) DV-2.




그림 6. 모델 별 테스트 결과: 보행자 횡단 시나리오. (a) UniAD. (b) DV-1. (c) DV-2.
Fig. 6. Test results by model: Pedestrian crossing scenario. (a) UniAD. (b) DV-1. (c) DV-2.

$$VPQ = \sum_{t=0}^H \frac{\sum_{(p_t, q_t) \in TP_t} \text{IoU}(p_t, q_t)}{|TP_t| + \frac{1}{2}|FP_t| + \frac{1}{2}|FN_t|} \quad (9)$$

여기서 H 는 예측 시간 범위(prediction horizon), TP_t 는 t 시점에서의 True Positive, FP_t 는 t 시점에서의 False Positive, FN_t 는 t 시점에서의 False Negative, p_t , q_t 는 예측된 객체와 ground truth 객체를 의미한다. 두 가지 평가 지표 모두 자율 주행차량에서 BEV 영역 기준 각각 근거리(30x30m)와 원거리(100mx100m) 범위에서 평가한다.

계획(planning)과 관련된 평가 지표는 UniAD의 방식을 따른다. L2 error (average L2 distance error)와 충돌률(collision rate)로 평가된다. L2 error는 예측된 궤적과 실제 궤적 사이의 유클리디안 거리의 평균값을 구하고, 각각 1초, 2초, 3초 시점에서의 충돌률을 평균으로 계산한다. 충돌률은 L2와 같은 시점을 평균 계산하며, 계획된 궤적의 각 웨이 포인트에 자율주행차량 박스를 배치하여 충돌 가능성을 평가한다. 이를 통해 주행 경로가 안전하고 정확하게 계획되었는지 확인할 수 있다.

3. 실험 결과

DV-1 및 DV-2의 구체적인 비교를 위해 BEV맵을 시각화 하였다. 그림 4는 UniAD의 단계 1의 추적 학습 과정에서 생성된 BEV 쿼리와 위치 정보를 통해 초기 BEV 특징치 맵(feature map)을 생성하고, 픽셀 별 특징 벡터 전체를 채널로 나눈 평균값을 시각화한 결과이다. 원본 UniAD 모델의 200x200 크기의 특징치 맵은 -0.0025에서 0.0150 범위의 활성화 값을 보이며, 주변 객체들이 인식되고 있는 모습을 확인할 수 있다. 경량화 모델 DV-1은 200x200 해상도를 유지하며 시각화 상으로는 -0.0006에서 0.0004 범위에서 패턴을 보여주었다. 원본 모델처럼 객체들이 보이지는 않지만, 중심부를 기준으로 방사형 패턴이 뚜렷하게 관찰되었다. DV-2의 50x50 특징치 맵은 -0.000003에서 0.000001 범위의 낮은 활성화 값을 보였다. 낮은 해상도와 알려진 구조 때문에 세부 정보가 손실되었지만, 동일하게 방사형 패턴을 띄고 있는 것을 확인할 수 있다. 실험에 사용한 두 개 버전의 구조의 구체적인 사양은 표 1에서 확인할 수 있다.

표 4. 모델별 계산 성능 비교.

Table 4. Comparison of computing performance by model.

Model	# Params	FLOPs	FPS
UniAD (Paper)(A100)	125.0M	1709G	1.8
UniAD (4090*2)	84.0M	2318G	2.4
DV-1 (4090*2)	25.5M	1859G	2.9
DV-2 (4090*2)	25.3M	1059G	3.4

표 3은 두 개의 경량화 모델 구조에 의한 실험 결과를 보여 주고 있다. DV-1에서는 프로토타입 실험 결과를 바탕으로 해상도는 200x200으로 증가하여 단계 1과 단계 2 모두 학습을 진행하였다. 프로토타입 실험과 비교하여 메모리 사용량이 79% 증가하였고, 일부 구조를 복원했음에도 불구하고, 추적 모듈의 AMOTA 값은 0에 수렴하는 결과를 보였다. 특히, EPA 값은 72286: Ground Truth (NGT), 10707: True Positive (TP, $|\hat{\text{match}}_{\text{hit}}|$), 32595: False Positive (NFP)값에 따라, 산출 근거에 의거하여 $\frac{(10707 - 0.5 \times 32595)}{72286} = -0.077$ 로 계산하였다. 이는 모델이 과다 예측(over-prediction)을 하고 있으며, 예측의 정확도가 낮음을 의미한다. 메모리는 1단계에서 65.77%, 2단계에서 37.61% 감소하였다.

DV-2에서는 Resnet-50으로 변경하고, 단계 1에서는 50x50 해상도로 학습한 뒤, 단계 2에서 200x200으로 확장하는 방식을 채택하였다. 그 결과 DV-1에 비해 성능이 향상되었으며, 특히 추적 모듈의 AMOTA 값이 0.016으로 개선되었다. 메모리는 단계 1에서 79.92%, 단계 2에서 38.81% 감소하였다.

그림 5와 그림 6은 각 모델별 실제 이미지에 적용한 결과를 보여주고 있다. 그림 5는 도심지 주행 시나리오에 해당하며 그림 6은 보행자 횡단 시나리오에 해당한다. 그림 5(a)는 원본 모델을 이용한 결과이며 6개의 서라운드 카메라 뷰에서 객체 탐지와 궤적 예측이 명확하게 수행되고 있다. 그림 5(b)는 DV-1 모델을 추론한 결과로 200x200 해상도를 유지하나, EPA 값에서 증명되었 듯 탐지된 보행자들이 과다 예측이 진행되고 있음을 확인할 수 있다. 그림 5(c)는 DV-2 모델의 추론 결과로 50x50 해상도로 축소되어 최소한의 객체 탐지 능력을 유지하며 단순화된 형태의 궤적을 예측한다.

결론적으로 경량화 과정에서 트랜스포머의 얹어진 레이어와 낮아진 해상도 때문에 특징점 학습이 충분히 진행되지 못하였다. 구체적으로, Resnet-101에서 Resnet-50으로 인코더를 변경 및 BEV 공간 해상도를 축소함으로써 표현능력이 감소한 것으로 보인다. 또한, 데이터에서 추출되는 정보를 감소하기 위한 쿼리 수 조정은 모델이 정확한 예측을 하기 어렵게 되었으며, 모델의 성능 저하로 이어졌다. 하지만, 단계적으로 해상도를 올리는 방식으로 학습한 DV-2는 인코더와 트랜스포머의 헤드 수를 낮췄음에도 불구하고, 전체 학습 과정에서 일정한 해상도를 유지한 DV-1보다 향상된 성능을 달성하였다. 표 4는 모델별 계산 성능을 비교해서 보여주고 있다.

VII. 결론

자율주행을 위한 풀 스택 프레임워크인 UniAD 모델은 고성능 하드웨어를 활용했음에도 불구하고, 복잡한 모델

구조로 인해 제한 요소가 다수 존재한다. 본 논문에서는 제한 요소 중 하나인 학습을 위해 고성능 하드웨어가 필요하다는 점을 해소하기 위해 구조를 경량화하여 메모리 소모를 줄이는 방안을 다루었다. 실험을 통해 트랜스포머 레이어 및 헤드 수 감소, 모듈의 쿼리 수 감소, CUDA 메모리 할당 임계 값 조정 등을 진행하여 효과적으로 메모리는 감소하였지만, 경량화 과정에서 인지 능력이 함께 감소하여 정보 추출 능력이 감소함을 알 수 있다. 결과값을 통해 DV-1보다 DV-2의 성능이 향상된 것을 보아, 해상도 축소가 반드시 전체 성능 저하로 이어지지 않음을 확인할 수 있었다. 이를 통해 대규모 멀티 모달 모델을 경량화하고 효율적인 학습하는데 있어 인자 수를 수를 조정하여 구조 축소 및 트랜스포머층을 알게 하는 접근법 보단, 시스템의 전반적인 구조를 감량하지 않고, 불필요한 과정을 건너 뛰는 접근이 필요하다는 것이 증명되었다.

향후 연구방향으로 DV-2에 적합한 단계적 해상도 확장 전략을 검증하기 위해 다른 모델에도 적용하여 성능 변화가 있는지 추가적인 검증을 수행할 예정이다. 또한, 기존 UniAD에서 학습시 주요 리소스를 차지하는 단계 1의 Trackformer와 Mapformer 모듈을 개선하는 방향으로 연구를 수행할 예정이다.

REFERENCES

- [1] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "Imagenet classification with deep convolutional neural networks," *Advances in Neural Information Processing Systems*, 2012.
- [2] OpenAI, "GPT-4 technical report," *arXiv:2303.08774*, 2023.
- [3] Y. Hu, J. Yang, L. Chen, K. Li, C. Sima, X. Zhu, S. Chai, S. Du, T. Lin, W. Wang, L. Lu, X. Jia, Q. Liu, J. Dai, Y. Qiao, and H. Li, "Planning-oriented autonomous driving," *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023.
- [4] M. Guo, Z. Zhang, Y. He, K. Wang, and L. Jing, "End-to-end autonomous driving without costly modularization and 3D manual annotation," *arXiv preprint arXiv:2406.17680*, 2024.
- [5] P. Li and D. Cui, "Does end-to-end autonomous driving really need perception tasks?," *arXiv preprint arXiv:2409.18341*, 2024.
- [6] G.-W. Kim and J.-Y. Kang, "3D space object and road detection for autonomous vehicles using monocular camera images and deep learning algorithms," *Journal of Institute of Control, Robotics and Systems (in Korean)*, vol. 30, no. 7, pp. 677-684, 2024.
- [7] H.-J. Sim, J. Kim, J.-G. Hong, S.-W. Nam, Y.-H. Kim, J. Heo, H.-C. Hwang, and K.-K. Kim, "Visual navigation in unstructured environments and the development of a multi-purpose mobile robot platform," *Journal of Institute of Control, Robotics and Systems (in Korean)*, vol. 30, no. 9, pp. 913-923, 2024.
- [8] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," *Proceedings of the 31st International Conference on Neural Information Processing Systems (NeurIPS)*, 2017.
- [9] Z. Li, W. Wang, H. Li, E. Xie, C. Sima, T. Lu, Y. Qiao, and J. Dai, "BEVFormer: Learning bird's-eye-view representation from multi-camera images via spatiotemporal transformers," *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022.

- [10] H. Caesar, V. Bankiti, A. H. Lang, S. Vora, V. E. Liong, Q. Xu, A. Krishnan, Y. Pan, G. Baldan, and O. Beijbom, "nuScenes: A multimodal dataset for autonomous driving," *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020.
- [11] M. Chang, J. Lambert, P. Sangkloy, J. Singh, S. Bak, A. Hartnett, D. Wang, P. Carr, S. Lucey, D. Ramanan, and J. Hays, "Argoverse: 3D tracking and forecasting with rich maps," *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019.
- [12] D. Kim, S. Lin, K. Shih, Y. Liu, T. Y. Lin, and M. H. Yang, "Video panoptic segmentation," *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020.
- [13] J. Gu, C. Hu, T. Zhang, X. Chen, Y. Wang, Y. Wang, and H. Zhao, "ViP3D: End-to-end visual trajectory prediction via 3D agent queries," *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 5496-5506, 2023.
- [14] M. Li, S. Wang, and J. Zhang, "Object detection based on lightweight YOLOX for autonomous driving," *Sensors*, vol. 23, no. 17, 2023.
- [15] Q. H. Che, V. N. Nguyen, and T. N. Nguyen, "TwinLiteNet: An efficient and lightweight model for driveable area and lane segmentation in self-driving cars," arXiv:2307.10705, 2023.
- [16] Y. Zhang, L. Chen, and H. Li, "Mobip: a lightweight model for driving perception using MobileNet," *Frontiers in Neurorobotics*, vol. 17, 2023.
- [17] A. Gopalkrishnan, R. Greer, and M. Trivedi, "Multi-frame, lightweight & efficient vision-language models for question answering in autonomous driving," arXiv:2403.19838, 2024.
- [18] A. Marchisio, G. Massari, and M. Martina, "CarSNN: An efficient spiking neural network for event-based autonomous cars," arXiv:2107.00401, 2021.
- [19] M. Lechner, R. Hasani, and D. Rus, "Neural circuit policies enabling auditable autonomy," *Nature Machine Intelligence*, vol. 3, pp. 47-456, 2021.



전 현 식

2024년 신한대학교 미래자동차공학과 졸업(공학사). 2024년~현재 서울과학기술대학교 자동차공학과 대학원 석사과정 관심분야는 딥러닝, 객체인지, 객체 추적.



박 상 민

2021년 대전대학교 정보통신·전자공학과 졸업(공학사). 2020년~2022년 (주)인텍플러스 비전연구소 연구원. 2022년~2024년 서울과학기술대학교 자동차공학과(공학석사). 관심분야는 딥러닝, 객체인지.



하 종 은

1992년 서울대 기계공학과(공학사). 1994년 서울대 기계공학과(공학석사). 2000년 KAIST 기계공학과(공학박사). 2000년~2002년 삼성코닝 Advanced Engineering Group 선임 연구원. 2002년~2005년 동명대학교 멀티미디어공학과. 2005년~현재 서울과학기술대학교 기계·자동차공학과 교수. 관심 분야는 딥러닝, 딥강화학습, 로봇 비전, 머신 비전.